

Relatório Executivo

Detecção de Falhas Industriais com MLOps, Métricas para Classes Desbalanceadas e Ajuste Dinâmico de Threshold

Indústria 4.0 | Dados sintéticos de sensores | 99,5% Operacional vs. 0,5% Falha

Volume	100.000	Split	70% treino / 15% validação / 15% teste
Taxa de falha	0.50%	Modelo	Pipeline: StandardScaler + Logistic Regression balanceada
Threshold padrão	0,50	Threshold otimizado	0.96
Custo padrão no teste	R\$ 920.000	Custo otimizado	R\$ 535.000
Economia	R\$ 385.000	Redução	41.85%

Objetivo

Construir uma solução reprodutível de Engenharia de Dados e MLOps para classificação de falhas raras em sensores industriais, demonstrando por que a acurácia não deve ser usada isoladamente, como a matriz de confusão altera a interpretação do modelo e como o threshold de decisão pode ser calibrado segundo o impacto operacional e financeiro.

1. Arquitetura da Solução e Prevenção de Data Leakage

O fluxo foi estruturado para preservar a independência estatística do conjunto de teste. A divisão estratificada ocorre antes do ajuste do pré-processamento: 70% dos registros formam o treinamento, 15% a validação e 15% o teste. O StandardScaler permanece dentro de um Pipeline do scikit-learn e é ajustado exclusivamente com X_train. A seleção do threshold econômico é feita sobre X_val, enquanto X_test permanece reservado para a mensuração final. Isso evita que médias, desvios-padrão, parâmetros do classificador ou decisões de threshold sejam influenciados pelo teste.

Etapa	Entrada	Operação	Saída
1. Geração	Distribuições sintéticas	Sensores + variável-alvo desbalanceada	100.000 registros
2. Split	Dataset completo	Estratificação	70% treino / 15% validação / 15% teste
3. Pré-processamento	X_train	StandardScaler	Parâmetros aprendidos só no treino
4. Treinamento	X_train + y_train	Logistic Regression balanceada	Modelo treinado
5. Calibração	X_val	Varredura de thresholds + função de custo	Threshold = 0.96
6. Avaliação	X_test	Métricas e matriz de confusão	Resultado final não usado para tuning

Regra de ouro de MLOps: qualquer transformação que estime parâmetros a partir dos dados deve ser ajustada apenas em treino, e decisões de hiperparâmetro/threshold devem utilizar validação. O teste deve aparecer uma única vez no encerramento do ciclo de avaliação.

2. Dados Sintéticos e Cenário de Desbalanceamento

Foram sintetizados 100.000 registros com seis sinais industriais: vibração RMS, temperatura, pressão, corrente elétrica, pico de aceleração e ruído acústico. A classe Falha representa aproximadamente 0,5% dos eventos,

conforme a situação proposta. Registros de falha recebem deslocamentos controlados nas distribuições dos sensores, mantendo sobreposição entre classes para evitar um problema artificialmente trivial.

Nesse regime, um classificador ingênuo que previsse sempre Operacional teria acurácia próxima de 99,5%, mas recall de 0% para a classe crítica. Portanto, a pergunta operacional relevante não é apenas 'quantos acertamos?', mas principalmente 'quantas falhas conseguimos capturar e a que custo em falsos alarmes?'.

3. Quadro Comparativo de Métricas

Métrica	Threshold 0,50	Threshold 0.96
Acurácia	98.95%	99.77%
TN	14.772	14.899
FP	154	27
FN	3	8
TP	71	66
Precisão	31.56%	70.97%
Recall	95.95%	89.19%
F1	47.49%	79.04%
F2	68.14%	84.83%
F0,5	36.45%	73.99%
AUC-ROC	99.73%	99.73%

Leitura técnica: a AUC-ROC permaneceu em torno de 0,997, indicando excelente capacidade de ordenação das probabilidades. O threshold, porém, modifica a matriz de confusão e, conseqüentemente, Precisão, Recall e F-beta. O F2 pesa mais o Recall (beta > 1), sendo mais coerente com situações em que perder uma falha é muito mais grave do que gerar um alarme adicional. Já F0,5 pesa mais a Precisão.




Figura 1 - Comparação das métricas no conjunto de teste.

4. Interpretação Matemática das Métricas

A matriz de confusão é definida por quatro contagens: **TP** (falha corretamente detectada), **TN** (operação corretamente identificada), **FP** (falso alarme) e **FN** (falha não detectada). A partir dessas quantidades, temos:

Acurácia	$(TP + TN) / (TP + TN + FP + FN)$
Precisão	$TP / (TP + FP)$
Recall	$TP / (TP + FN)$
F_beta	$(1 + \beta^2) * Precisão * Recall / (\beta^2 * Precisão + Recall)$

Na classe rara, a Acurácia sofre de efeito de prevalência: milhares de TN podem dominar a razão mesmo quando o modelo tem desempenho ruim na classe Falha. Por isso, o relatório prioriza a matriz de confusão, Recall, Precisão, família F-beta e AUC-ROC.




Figura 2 - Curva ROC no conjunto de teste; AUC elevada indica separabilidade forte entre as classes.

5. Ajuste Dinâmico do Threshold e Análise Financeira

Foi adotada uma função de custo simples e auditável: **Custo Total = FN x R\$ 50.000 + FP x R\$ 5.000**. O custo de um FN representa uma falha grave perdida, com potencial para parada não planejada, manutenção emergencial e risco operacional. O custo de um FP representa um falso alarme, com inspeção, intervenção ou parada preventiva. Nesta simulação, FN vale 10 vezes FP.




Figura 3 - Custo total no conjunto de validação utilizado para selecionar o threshold; o valor selecionado foi 0.96.

Aplicando o threshold selecionado ao teste final, o custo estimado passou de **R\$ 920.000** no threshold 0,50 para **R\$ 535.000**. A economia foi de **R\$ 385.000**, equivalente a **41.85%**. O modelo, contudo, passou a gerar uma decisão mais conservadora em relação a falsos alarmes: o número de FP caiu de 154 para 27, enquanto FN subiu de 3 para 8. Isso ilustra que threshold ótimo depende da função de perda da operação, e não de uma regra universal de 0,50.

Observação metodológica

Para evitar overfitting do threshold ao teste, a busca do ponto de menor custo foi feita no conjunto de validação. O conjunto de teste somente recebeu o threshold já escolhido e foi usado para estimar o desempenho final. Em um sistema industrial real, a função de custo deve ser revisada com dados históricos de manutenção, tempo de parada, SLA, criticidade do ativo e custo de intervenção.

6. Recomendações MLOps para Produção

Área	Prática recomendada
Monitoramento de dados	Acompanhar distribuição dos sensores, taxa de eventos ausentes, outliers, drift e prevalência da classe Falha. Al
Monitoramento do modelo	Monitorar Recall, Precisão, F-beta, AUC-ROC e principalmente FN. Quando a verdade de campo chegar com atra
Threshold	Manter o threshold como parâmetro versionado e configurável. Alterações devem ser registradas como mudançã
Observabilidade	Registrar timestamp, ativo, versão do modelo, versão dos dados, probabilidade estimada, threshold aplicado e de
Retreinamento	Definir gatilhos por drift, degradação de métricas ou mudança do processo industrial. Reexecutar pipeline em am
Governança	Separar treino, validação e teste; controlar sementes aleatórias; versionar código, dependências e datasets; e util

7. Conclusão Executiva

O experimento demonstra que, em cenários industriais fortemente desbalanceados, a acurácia não é uma métrica suficiente para orientar uma decisão de produção. A separação entre treino, validação e teste protege contra leakage e torna o experimento reproduzível. O modelo apresentou AUC-ROC de 0.9973, indicando forte capacidade discriminativa; entretanto, a escolha de threshold alterou significativamente o equilíbrio entre falsos positivos e falsos negativos. Sob a função de custo adotada, o threshold 0.96 reduziu o custo do teste em R\$ 385.000, demonstrando o valor de conectar MLOps, métricas e economia operacional em uma mesma camada decisória.

A entrega acompanha o código-fonte, as dependências, os dados sintéticos, os gráficos e os resultados numéricos. O projeto pode ser reexecutado no VSCode a partir do ``requirements.txt`` e do script ``src/main.py``.